

HS-Guard

AI4AI 案例：AI 如何接入 Aster 和 GPU 集群，完成安全模型的训练与交付。

把安全审核接入模型生成过程

人在这个项目中确定安全边界、召回目标和误报预算。AI 根据这些要求编写数据处理与训练代码，通过工具调用 Aster 标注任务和 GPU 作业，读取实验结果，再推进下一轮调整。最终交付包括模型权重、流式推理引擎、评测记录和技术报告。

98.25%

红线回答召回率

112 / 114 · Qwen3Guard 0.6B: 92.11%

2.38 ms

增量审核延迟 P50

NVIDIA L20 · 8,000-token context

352

并发审核流

30–60 tokens/s per stream · P95 < 20 ms

01 从已有基座到专用模型

HS-Guard 基于 Qwen3.5-0.8B-Base 适配，最终包含 7.545 亿参数。模型分别审核提问与回答，并提供红线和通用安全两类判断。

02 训练之后，继续做交付

审核引擎保留历史状态，每到一个新 token 就更新风险分数。AI 随后完成引擎打包、独立环境复测、模型完整性检查和开源材料整理。

AI × Infrastructure

用工具接口连接任务、数据、算力和实验结果。

AI 通过 CLI 和 Python 工具接入我们的基础设施。Aster 平台执行数据标注流程；训练与推理由 L20 集群运行。AI 负责提交任务、检查状态、读取日志、处理执行故障，并收取结果。

Aster CLI: datasets / runs · GPU jobs: Kubernetes · Artifacts: GitHub / Hugging Face

01 / OBJECTIVE

人：定义目标

明确审核政策、优先改进的指标、误报预算和算力范围。

02 / AGENT

AI：编写并执行

维护数据、训练和评测脚本，通过工具调用平台，依据状态和日志继续执行。

03 / ASTER

Aster：数据任务

发布数据版本，检查运行计划，执行标注流程，返回标签与任务记录。

04 / GPU JOBS

L20：训练与推理

通过 Kubernetes 提交作业，保存权重与日志，并检查已有任务的运行状态。

05 / EVALUATION

AI：评测与验收

汇总分数、延迟和吞吐；检查数据与权重完整性；依据预设规则选择候选。

06 / RELEASE

开源：交付结果

整理模型、引擎、报告和示例；移除内部配置，发布可下载的独立软件包。

实验结果回到 AI 的工作上下文：检查失败的任务、比较候选版本、决定下一步执行。策略和目标变化由人给出，作业状态与评测记录提供下一轮工作的依据。

Data Production

一轮可追踪的数据生产：采样、去重、标注、检查，再进入训练。

6,000

新提问进入标注

1,500 tasks × 4 prompts

500

任务并发配置

1,500 / 1,500 tasks completed

98.33%

自动检查可用率

5,900 / 6,000 labels

01 先确定数据范围

从公开提问池采样，对照 200,419 个旧提问视图检查重合。排除 6,131 条旧数据或基准家族重合记录，以及 454 条池内重复。标注前固定训练、校准与审计划分。

02 把标注写成 Aster 流程

AI 将提问打包为任务，发布数据版本并检查运行计划。Aster 按配置并发执行裁判与政策处理流程；AI 收取归档，核对流程版本与标签质量。

03 质量检查决定能否训练

自动检查排除 96 条风险起点不一致的标签和 4 条裁判错误。AI 再复核 60 条训练样本，排除 8 条存疑记录；最终新增训练样本 4,430 条。

04 为评测保留新样本

新增校准样本 728 条，另保留 734 条有效审计样本。标签由自动裁判产生，抽查由 AI 完成。审计样本不进入训练或模型选择。

Training & Selection

从模型适配到定向微调，让训练范围与目标一致。

01 建立审核能力

前期 v5 适配使用 170,512 条文本，单轮约 2,160 万输入 token，在一张 L20 上训练两轮，耗时 88 分钟。后续实验分别调整提问和回答的审核能力。

02 集中改进提问分支

最终一轮从 v9 出发，仅更新提问头的 527,363 个参数。67,341 条混合样本训练两轮；回答、通用分支和主干保持固定。

8.15M

本轮累计训练 tokens

8,148,474 tokens · 8,418 steps

8m 24s

本轮训练作业时间

训练与校准主体：434.73 s

3m 59s

正式评测作业时间

运行于 L20 集群

将校准带来的变化与训练收益分开计算

按本轮规则重新校准后的 v9，提问召回为 96.34%；微调后的 v10 为 97.38%，多识别 2 条红线提问。两者安全提问误报均为 30.90%。此处使用同一组 191 条红线和 178 条安全提问。

候选模型由校准集选择。收取阶段核验输入、权重与分数，并逐条比较 9,204 条回答分数，确认回答行为保持一致。最终发布 24 层版本及其流式推理实现。


Safety

面向生成过程的安全审核。回答审核与通用安全任务中的代表性结果。

HS-Guard v10 Qwen3Guard 0.6B


Response Recall

回答红线召回率 (%) ↑ · 114 examples




False Positives

安全回答误报率 (%) ↓ · 203 examples




ToxicChat

Prompt F1 (%) ↑ · General safety



Aegis 2.0

Response F1 (%) ↑ · General safety



+6.14 pp recall

33.3% fewer false positives

Selected results · Same-example comparison · Full evaluation: Technical Report

Streaming

HS-Guard v10

Qwen3Guard 0.6B

单卡实时审核。历史上下文从 512 扩展到 8,000 tokens，增量服务延迟保持约 2.38 ms。

512 tokens

Single-token latency, P50 (ms) ↓



4.9x faster

2,048 tokens

Single-token latency, P50 (ms) ↓



4.9x faster

8,000 tokens

Single-token latency, P50 (ms) ↓



5.3x faster

Concurrent Moderation

NVIDIA L20 · 30-60 tokens/s per stream

CONCURRENT STREAMS

352

P95 <= 20 ms at all three contexts

AUDIT THROUGHPUT

15.1k token/s

Minimum across six measurements

P95 LATENCY

18.37 ms

Worst of two seeds at 352 streams

Warm incremental serving. Qwen baseline: SGLang 0.5.3rc0 with radix cache enabled.

Model-engine timings; tokenization, prefill and transport are outside the measured interval.

Open Release

模型、流式推理引擎和技术报告。

HS-Guard v10

754.5M parameters · 24 layers · Hybrid recurrent state + W512 attention

开源包包含模型加载器、增量审核引擎、推理示例和评测汇总。

从 token 输入到风险判定，可在自己的 GPU 环境中运行。

GitHub

流式引擎、加载器与示例

<https://github.com/KrisLiu16/HS-Guard>

Hugging Face

完整权重与 tokenizer

<https://huggingface.co/KrisLiu16/HS-Guard-v10>

Technical Report

架构、训练与评测方法

https://github.com/KrisLiu16/HS-Guard/blob/main/docs/technical_report.pdf

Code: Apache-2.0 | Weights: CC BY-NC 4.0 (noncommercial research)

Zhihao Liu · Naive N0.5